



UNIVERSIDAD TECNOLÓGICA CENTROAMERICANA

FACULTAD DE INGENIERÍA

PROYECTO DE GRADUACIÓN

**DISEÑO E IMPLEMENTACIÓN DE UNA ARQUITECTURA BASADA EN RAG PARA
ASESORÍA ACADÉMICA INTELIGENTE MEDIANTE EL ROBOT HUMANOIDE ADAI**

PREVIO A LA OBTENCIÓN DEL TÍTULO

INGENIERO EN SISTEMAS COMPUTACIONALES

PRESENTADO POR:

22111095 STEVE HENRY RIVERA CERRATO

ASESOR: ALBERTO MAX CARRASCO

CAMPUS SAN PEDRO SULA, MARZO, 2026

RESUMEN EJECUTIVO

En los últimos años, la integración de inteligencia artificial en sistemas robóticos ha ampliado las posibilidades de interacción entre humanos y máquinas dentro de entornos educativos. Los robots humanoides han comenzado a utilizarse como herramientas de apoyo en procesos de enseñanza, facilitando la comunicación entre los estudiantes y los sistemas digitales. En este contexto, surgió la necesidad de dotar a estos sistemas de mecanismos que les permitieran comprender y responder consultas académicas de forma flexible y fundamentada en información institucional.

El presente proyecto tuvo como objetivo diseñar e integrar una arquitectura conversacional inteligente en el robot humanoide educativo ADAI, con el fin de superar las limitaciones de los sistemas basados en secuencias preprogramadas. El problema identificado consistió en la dependencia de guiones estáticos que restringían la capacidad del robot para interactuar de manera adaptable dentro del entorno universitario y responder consultas abiertas.

Para abordar esta situación, se implementó una arquitectura basada en modelos de lenguaje de gran escala complementados con un mecanismo de recuperación semántica de información. La solución se fundamentó en la técnica de Recuperación Aumentada por Generación (RAG), mediante la cual las consultas se transformaron en representaciones vectoriales que permitieron recuperar fragmentos relevantes de documentación académica almacenada en una base vectorial. Posteriormente, dichos fragmentos se utilizaron como contexto para generar respuestas en lenguaje natural alineadas con la normativa institucional.

Como resultado, el robot evolucionó hacia una plataforma conversacional más adaptable y contextualizada, capaz de responder consultas académicas de forma más precisa y fundamentada. Palabras clave: robótica humanoide, inteligencia artificial, recuperación aumentada por generación, sistemas conversacionales.

ABSTRACT

In recent years, the integration of artificial intelligence into robotic systems has expanded the possibilities for human-machine interaction within educational environments. Humanoid robots have increasingly been used as support tools in teaching processes, facilitating communication between students and digital information systems. In this context, the need emerged to equip these systems with mechanisms capable of understanding and responding to academic inquiries in a flexible manner based on institutional information.

The objective of this project was to design and integrate an intelligent conversational architecture into the ADAI educational humanoid robot in order to overcome the limitations of systems based on preprogrammed sequences. The identified problem consisted of the reliance on static scripts, which restricted the robot's ability to interact adaptively within the university environment and respond to open academic questions.

To address this situation, an architecture based on large language models combined with a semantic information retrieval mechanism was implemented. The proposed solution relied on the Retrieval-Augmented Generation (RAG) technique, through which user queries were transformed into vector representations that enabled the retrieval of relevant fragments from academic documentation stored in a vector database. These fragments were then used as contextual information for generating natural language responses aligned with institutional regulations.

As a result, the robot evolved into a more adaptable and context-aware conversational platform capable of providing more accurate and grounded academic responses. Keywords: humanoid robotics, artificial intelligence, retrieval-augmented generation, conversational systems.

ÍNDICE DE CONTENIDO

I.	Introducción.....	3
II.	Planteamiento del Problema	5
	2.1 Precedentes del Problema.....	5
	2.2 Definición del Problema.....	6
	2.3 Justificación.....	6
	2.4 Preguntas de Investigación.....	7
	2.5 Objetivos	7
	2.5.1 Objetivo General.....	7
	2.5.2 Objetivos Específicos.....	8
III.	Marco Teórico.....	9
	3.1 Robótica Humanoide en el Ámbito Educativo.....	9
	3.1.1 Interacción Humano-Robot (HRI).....	10
	3.1.2 Limitaciones de los Enfoques Basados en Secuencias Predefinidas.....	10
	3.2 Sistemas Conversacionales y Procesamiento del Lenguaje Natural.....	10
	3.2.1 Evolución de los Chatbots a los Modelos Generativos.....	11
	3.2.1 Limitaciones de los Modelos Generativos Sin Contexto Externo.....	12
	3.3 Modelos de Lenguaje de Gran Escala (LLM).....	12
	3.3.1 Arquitectura Transformer y Mecanismo de Atención.....	13
	3.3.2 Ventana de Contexto y Escalabilidad.....	13
	3.3.3 Riesgo de Alucinación y Necesidad de Control.....	14
	3.4 Recuperación de Información y Búsqueda Semántica	14
	3.4.1 Búsqueda Léxica vs. Búsqueda Semántica.....	15
	3.4.2 Limitaciones de la Recuperación Tradicional en Entornos Dinámicos	15
	3.5 Representación Vectorial y Embeddings.....	16

3.5.1 De Representaciones Locales a Representaciones Contextuales	16
3.5.2 Embeddings a Nivel de Documento	17
3.5.3 Rol de los Embeddings en Sistemas Conversacionales	17
3.6 Recuperación Aumentada por Generación (RAG)	18
3.6.1 Arquitectura Conceptual de RAG	18
3.6.2 Ventajas de RAG en Entornos Académicos.....	19
3.6.3 RAG como Estrategia de Control de Dominio.....	19
3.7 Bases de Datos Vectoriales.....	20
3.7.1 Diferencias con Bases de Datos Relacionales	20
3.7.2 Indexación y Búsqueda de Vecinos Cercanos.....	21
3.7.3 Rol de las Bases Vectoriales en Arquitecturas RAG	21
3.8 Integración de Arquitecturas Conversacionales en Sistemas Robóticos Educativos	22
3.8.1 Arquitectura Modular y Separación de Responsabilidades	23
3.8.2 Consideraciones de Escalabilidad y Mantenimiento.....	24
3.8.3 Aplicación Conceptual al Presente Proyecto	24
3.9 Limitaciones de los Enfoques Analizados.....	25
IV. Metodología	26
4.1 Enfoque.....	26
4.2 Variables de Investigación	26
4.3 Técnicas e Instrumentos Aplicados	27
4.3.1 Modelos de Lenguaje de Gran Escala (LLM)	27
4.3.2 Recuperación Aumentada por Generación (RAG).....	28
4.3.3 Representación Vectorial y Embeddings	30
4.3.4 Bases de Datos Vectoriales	31
4.3.5 Pruebas con Usuarios y Encuestas de Satisfacción.....	33

4.4 Materiales	34
4.4.1 Hardware	34
4.4.2 Software	35
4.4.3 Herramientas Adicionales.....	37
4.5 Metodología de Estudio.....	37
4.5.1 Análisis del Sistema Existente	38
4.5.2 Diseño de la Arquitectura Conversacional.....	38
4.5.3 Procesamiento e Indexación de Documentos.....	39
4.5.4 Implementación del Sistema RAG.....	40
4.5.5 Integración con el Robot Humanoide ADAI.....	40
4.5.6 Pruebas del Sistema con Estudiantes	41
4.6 Metodología de Validación	41
4.6.1 Evaluación de precisión de respuestas.....	42
4.6.2 Medición del tiempo de respuesta.....	42
4.6.3 Evaluación de satisfacción del usuario	42
4.6.4 Análisis de resultados	43
4.7 Cronograma de Actividades	44
Bibliografía.....	45

ÍNDICE DE ILUSTRACIONES

Ilustración 1-Arquitectura conceptual del sistema.....	23
--	----

ÍNDICE DE TABLAS

Tabla 1-Limitaciones técnicas y operativas del sistema propuesto	25
--	----

Tabla 2-Cronograma de actividades a realizar durante el proyecto.....	44
---	----

LISTA DE SIGLAS Y GLOSARIO

ADAI: Robot humanoide educativo desarrollado en la Universidad Tecnológica Centroamericana (UNITEC) utilizado como plataforma de interacción académica con estudiantes.

API: Interfaz de Programación de Aplicaciones que permite la comunicación entre distintos sistemas de software mediante solicitudes estructuradas.

Base de datos vectorial: Sistema de almacenamiento diseñado para gestionar representaciones vectoriales de datos y realizar búsquedas de similitud semántica entre vectores de alta dimensión.

ChromaDB: Base de datos vectorial utilizada para almacenar embeddings de documentos y permitir búsquedas semánticas eficientes dentro de sistemas basados en recuperación de información.

Embedding: Representación numérica de texto dentro de un espacio vectorial que permite medir similitud semántica entre palabras, frases o documentos.

HRI: Interacción Humano-Robot (Human-Robot Interaction), disciplina que estudia la comunicación y relación entre personas y sistemas robóticos.

InMoov: Plataforma de robot humanoide de código abierto desarrollada por Gaël Langevin que sirve como base para proyectos de robótica humanoide personalizados.

IR: Recuperación de Información (Information Retrieval), área de estudio enfocada en localizar información relevante dentro de grandes colecciones de datos.

LLM: Modelo de Lenguaje de Gran Escala (Large Language Model), sistema de inteligencia artificial entrenado con grandes volúmenes de texto para comprender y generar lenguaje natural.

PLN: Procesamiento del Lenguaje Natural, campo de la inteligencia artificial dedicado al análisis, comprensión y generación del lenguaje humano por sistemas computacionales.

RAG: Recuperación Aumentada por Generación (Retrieval-Augmented Generation), técnica que combina recuperación de información con modelos generativos de lenguaje para producir respuestas fundamentadas en documentos externos.

Transformer: Arquitectura de redes neuronales basada en mecanismos de atención utilizada en modelos modernos de procesamiento del lenguaje natural.

UNITEC: Universidad Tecnológica Centroamericana, institución de educación superior donde se desarrolla el proyecto de investigación.

I. INTRODUCCIÓN

La evolución de la robótica humanoide y de la inteligencia artificial continuará redefiniendo los procesos de aprendizaje dentro de la educación superior. En los últimos años, la integración de robots en entornos académicos ha demostrado su potencial como herramienta de apoyo docente, permitiendo complementar la enseñanza tradicional mediante interacción verbal, gestual y tecnológica. Paralelamente, el desarrollo de modelos de lenguaje de gran escala y técnicas avanzadas de recuperación de información ha abierto nuevas posibilidades para la creación de sistemas conversacionales más precisos, escalables y contextualizados.

En la Universidad Tecnológica Centroamericana (UNITEC), campus San Pedro Sula, se desarrolló previamente el robot humanoide ADAI InMoov como herramienta de apoyo a la docencia, integrando sistemas electromecánicos y de control que le permiten ejecutar movimientos, gestos y secuencias programadas en el aula. Este proyecto estableció una base sólida en cuanto a interacción humano-robot en el ámbito educativo; sin embargo, su funcionamiento se encuentra principalmente orientado a la ejecución de contenidos predefinidos, limitando su capacidad para responder dinámicamente a consultas académicas generales.

A partir de estos antecedentes, el presente proyecto buscará extender las capacidades funcionales de ADAI hacia un rol de asesor académico inteligente orientado a estudiantes universitarios. Para ello, se propondrá el diseño e implementación de una arquitectura basada en la técnica de Recuperación Aumentada por Generación (Retrieval-Augmented Generation, RAG), la cual permitirá integrar modelos de lenguaje con mecanismos de recuperación de información a partir de documentos institucionales y fuentes académicas relevantes. Este enfoque posibilitará que el robot genere respuestas fundamentadas en información verificable, mejorando la precisión y reduciendo respuestas no sustentadas.

El objetivo general será diseñar una arquitectura conversacional escalable que permita la integración eficiente de procesamiento de lenguaje natural, recuperación semántica de información y sistema de control robótico, transformando a ADAI de un sistema de secuencias programadas a un asistente académico interactivo. Con ello, se pretende ampliar el alcance funcional del robot dentro del entorno universitario, estableciendo bases técnicas para futuras implementaciones de inteligencia artificial aplicada a la educación superior en UNITEC.

El presente informe se estructurará de la siguiente manera: en el Capítulo II se desarrollará el planteamiento del problema, incluyendo sus antecedentes, definición, justificación y preguntas de investigación. En el Capítulo III se abordará el marco teórico, donde se analizarán los fundamentos relacionados con robótica humanoide, sistemas conversacionales, modelos de lenguaje y arquitectura RAG. En el Capítulo IV se describirá la metodología utilizada para el diseño e integración del sistema propuesto. Finalmente, se presentarán los resultados, conclusiones y recomendaciones correspondientes.

II. PLANTEAMIENTO DEL PROBLEMA

El presente capítulo expone el planteamiento del problema que motiva el desarrollo de esta investigación. En primer lugar, se describen los antecedentes relacionados con el uso del robot humanoide ADAI dentro del entorno académico de la Universidad Tecnológica Centroamericana (UNITEC). Posteriormente, se presenta la definición del problema identificado, así como la justificación que sustenta la necesidad de proponer una solución tecnológica basada en inteligencia artificial. Finalmente, se formulan las preguntas de investigación y los objetivos que orientan el desarrollo del proyecto.

2.1 PRECEDENTES DEL PROBLEMA

El desarrollo de robots humanoides en entornos educativos ha representado un avance significativo en la integración de tecnología dentro del aula universitaria. En la Universidad Tecnológica Centroamericana (UNITEC), campus San Pedro Sula, se desarrolló el robot humanoide ADAI InMoov como una herramienta de apoyo docente, capaz de ejecutar secuencias programadas, gestos y verbalizaciones para complementar la enseñanza. Este proyecto estableció una base sólida en cuanto a interacción humano-robot, integración mecatrónica y sistemas de control en el contexto académico.

Posteriormente, el sistema fue conectado a modelos de lenguaje de OpenAI, permitiendo que el robot pudiera generar respuestas dinámicas ante consultas realizadas por los estudiantes. Sin embargo, el mecanismo actual de generación de respuestas se basa principalmente en el envío de grandes bloques de texto como contexto al modelo, lo cual limita la eficiencia, escalabilidad y precisión cuando se trabaja con múltiples documentos institucionales o grandes volúmenes de información.

En su estado actual, ADAI puede responder preguntas generales; no obstante, no cuenta con una arquitectura estructurada de recuperación semántica que permita consultar de forma selectiva y fundamentada documentos académicos específicos de la universidad. Esta situación restringe su potencial como asesor académico formal, especialmente cuando se requiere garantizar que las respuestas estén sustentadas en información institucional verificable.

2.2 DEFINICIÓN DEL PROBLEMA

Actualmente, el robot humanoide ADAI genera respuestas dinámicas mediante el envío del texto completo de un documento en formato PDF como contexto al modelo de lenguaje, lo que permite limitar parcialmente las respuestas al contenido proporcionado. Sin embargo, este enfoque presenta restricciones técnicas cuando se requiere manejar múltiples documentos institucionales o grandes volúmenes de información, debido a limitaciones de contexto, eficiencia y escalabilidad. La ausencia de un mecanismo de recuperación semántica estructurada impide seleccionar de forma específica los fragmentos más relevantes para cada consulta, lo que dificulta garantizar precisión, control de dominio institucional y crecimiento futuro del sistema como asesor académico formal dentro de UNITEC.

2.3 JUSTIFICACIÓN

La implementación de una arquitectura basada en Recuperación Aumentada por Generación (RAG) para transformar al robot humanoide ADAI en un asesor académico institucional representa una evolución natural del proyecto desarrollado previamente en UNITEC. Si bien el robot ha demostrado su utilidad como herramienta de apoyo en el aula, su capacidad de asesoría académica formal requiere una estructura más robusta que garantice precisión, fundamentación documental y control de dominio sobre la información generada.

Desde la perspectiva institucional, el desarrollo de un asesor académico inteligente fundamentado exclusivamente en documentos oficiales permitiría a la Universidad Tecnológica Centroamericana (UNITEC), campus San Pedro Sula, contar con un prototipo tecnológicamente avanzado que podría escalarse como herramienta de consulta para estudiantes. Este sistema podría facilitar el acceso a reglamentos académicos, información administrativa, lineamientos institucionales y otros recursos oficiales, contribuyendo a mejorar la experiencia estudiantil mediante respuestas inmediatas y verificables.

Desde el enfoque ingenieril, el proyecto aporta el diseño e integración de una arquitectura conversacional escalable que combina modelos de lenguaje, recuperación semántica de información y sistemas robóticos interactivos. La incorporación de RAG no solo mejora la eficiencia y precisión en la generación de respuestas, sino que introduce un mecanismo estructurado que permite el manejo de múltiples fuentes documentales sin depender del

envío completo de grandes volúmenes de texto al modelo. Esto fortalece la confiabilidad del sistema y sienta bases técnicas para futuras ampliaciones dentro de la universidad.

Finalmente, el proyecto tiene potencial de reutilización y expansión institucional, ya que la arquitectura propuesta podría adaptarse a otros contextos educativos o integrarse en plataformas digitales universitarias más amplias, posicionando a UNITEC como una institución que integra soluciones avanzadas de inteligencia artificial aplicada a la educación superior.

2.4 PREGUNTAS DE INVESTIGACIÓN

- ¿Cómo diseñar una arquitectura conversacional basada en Recuperación Aumentada por Generación (RAG) que permita integrar modelos de lenguaje con el robot humanoide ADAI para su funcionamiento como asesor académico institucional?
- ¿De qué manera se pueden procesar e indexar documentos académicos institucionales para garantizar una recuperación semántica eficiente y fundamentada en cada consulta realizada por estudiantes?
- ¿Cómo integrar el sistema de recuperación de información con el módulo de interacción del robot (voz, animaciones y control) asegurando coherencia y control de dominio institucional en las respuestas generadas?
- ¿Es factible implementar un prototipo funcional que permita validar el desempeño del asesor académico mediante pruebas reales con estudiantes universitarios?

2.5 OBJETIVOS

Los objetivos de la presente investigación orientan el desarrollo del proyecto y establecen los resultados que se buscan alcanzar mediante el diseño e implementación de la arquitectura conversacional propuesta. A través de estos objetivos se define el propósito general del estudio y las acciones específicas necesarias para desarrollar, integrar y evaluar el sistema basado en Recuperación Aumentada por Generación (RAG) aplicado al robot humanoide ADAI dentro del entorno académico de la Universidad Tecnológica Centroamericana (UNITEC).

2.5.1 OBJETIVO GENERAL

Diseñar e implementar una arquitectura conversacional basada en Recuperación Aumentada por Generación (RAG), integrada al robot humanoide ADAI, que permita su funcionamiento

como asesor académico inteligente para estudiantes de la Universidad Tecnológica Centroamericana (UNITEC), campus San Pedro Sula.

2.5.2 OBJETIVOS ESPECÍFICOS

- Analizar la arquitectura actual del robot humanoide ADAI para identificar los puntos de integración del sistema conversacional propuesto, mediante la documentación y caracterización de los componentes existentes y sus interfaces de comunicación.
- Diseñar e implementar un sistema de procesamiento e indexación de documentos académicos institucionales mediante técnicas de segmentación y generación de representaciones vectoriales (*embeddings*), permitiendo su almacenamiento y consulta eficiente dentro de una base de datos vectorial.
- Desarrollar e integrar un mecanismo de recuperación semántica y generación de respuestas basado en el enfoque RAG, garantizando que las respuestas generadas por el sistema estén fundamentadas en fragmentos relevantes de documentación institucional.
- Evaluar el funcionamiento del sistema mediante pruebas controladas con estudiantes universitarios, midiendo indicadores como precisión de las respuestas, tiempo de respuesta del sistema y nivel de satisfacción de los usuarios durante la interacción con el robot humanoide ADAI.

III. MARCO TEÓRICO

3.1 ROBÓTICA HUMANOIDE EN EL ÁMBITO EDUCATIVO

La robótica humanoide constituye una rama especializada de la ingeniería robótica orientada al desarrollo de sistemas con características físicas y comportamentales similares a las del ser humano. Estos sistemas integran componentes mecánicos, electrónicos y de control que les permiten ejecutar movimientos articulados, responder a estímulos y establecer distintos niveles de interacción social. Dentro de este campo, la interacción humano-robot (Human-Robot Interaction, HRI) analiza cómo las personas perciben, interpretan y responden a la presencia de sistemas robóticos en entornos reales (Dautenhahn, 2007).

En el ámbito educativo, los robots humanoides han sido incorporados como herramientas de apoyo pedagógico, especialmente en áreas relacionadas con ciencia, tecnología e ingeniería. Su utilización busca reforzar conceptos mediante demostraciones físicas, interacción verbal y dinámicas participativas. Según Mubin et al. (2013), la presencia de robots en el aula puede incrementar el nivel de atención y motivación de los estudiantes, aunque su impacto depende directamente del grado de interacción significativa que logren establecer.

Desde una perspectiva técnica, muchos de los primeros robots educativos operan mediante secuencias programadas y respuestas predefinidas. Este enfoque permite un control preciso del comportamiento del sistema, pero restringe su capacidad de adaptación frente a preguntas abiertas o escenarios no previstos. Breazeal (2003) señala que los robots sociales requieren no solo capacidades mecánicas avanzadas, sino también mecanismos de interpretación contextual para sostener interacciones naturales y coherentes.

En contextos universitarios, donde las consultas pueden abarcar reglamentos, procesos académicos y normativas institucionales cambiantes, la dependencia exclusiva de guiones preestablecidos resulta insuficiente. Por ello, la evolución de los sistemas robóticos educativos ha comenzado a integrar técnicas avanzadas de procesamiento del lenguaje natural y acceso estructurado a la información, permitiendo ampliar su funcionalidad más allá de la ejecución de scripts estáticos.

3.1.1 INTERACCIÓN HUMANO-ROBOT (HRI)

La HRI estudia los principios que permiten una comunicación efectiva entre humanos y sistemas robóticos. Esta interacción puede involucrar señales verbales, visuales y gestuales, y su éxito depende tanto del diseño físico del robot como de su arquitectura cognitiva. Dautenhahn (2007) sostiene que la aceptación social de un robot depende de su capacidad para generar respuestas previsibles, coherentes y contextualizadas.

En el entorno educativo, la comunicación verbal adquiere un papel central. No es suficiente que el sistema ejecute movimientos coordinados; debe ser capaz de comprender y generar lenguaje natural. Cuando esta capacidad es limitada, la interacción se reduce a comandos estructurados, lo que puede afectar la percepción de inteligencia del sistema y disminuir la fluidez conversacional.

3.1.2 LIMITACIONES DE LOS ENFOQUES BASADOS EN SECUENCIAS PREDEFINIDAS

Los sistemas programados mediante guiones o scripts funcionan adecuadamente cuando el flujo de interacción está completamente delimitado. Sin embargo, presentan limitaciones importantes en escenarios dinámicos.

Entre las principales restricciones se encuentran:

- Dependencia de escenarios anticipados durante la fase de diseño.
- Dificultad para responder preguntas no previstas.
- Escasa escalabilidad frente a nuevas necesidades institucionales.

La transición hacia sistemas robóticos con capacidades conversacionales más flexibles requiere integrar modelos capaces de interpretar lenguaje natural y consultar fuentes externas de información. Esta evolución tecnológica constituye el fundamento conceptual del enfoque propuesto en el presente proyecto.

3.2 SISTEMAS CONVERSACIONALES Y PROCESAMIENTO DEL LENGUAJE NATURAL

El desarrollo de sistemas conversacionales ha experimentado una evolución significativa en las últimas décadas. Inicialmente, los denominados chatbots operaban mediante reglas predefinidas y patrones estructurados, donde cada posible entrada del usuario debía estar anticipada en un conjunto de respuestas programadas. Este enfoque, aunque funcional en

entornos controlados, resultaba limitado cuando la interacción requería flexibilidad o comprensión semántica más profunda.

El Procesamiento del Lenguaje Natural (PLN) surge como una disciplina dentro de la inteligencia artificial orientada a permitir que los sistemas computacionales comprendan, interpreten y generen lenguaje humano. Según Jurafsky y Martin (2021), el PLN combina métodos lingüísticos, estadísticos y computacionales para modelar la estructura y el significado del lenguaje. Este campo ha dado origen a aplicaciones como sistemas de respuesta automática, traductores, asistentes virtuales y motores de búsqueda inteligentes.

En entornos académicos, los sistemas conversacionales adquieren especial relevancia cuando se busca facilitar el acceso a información técnica o normativa sin exigir conocimientos especializados. A diferencia de una interfaz tradicional basada en menús o formularios, una interfaz conversacional permite que el usuario formule preguntas de manera natural, reduciendo barreras técnicas y mejorando la accesibilidad del sistema.

3.2.1 EVOLUCIÓN DE LOS CHATBOTS A LOS MODELOS GENERATIVOS

Los primeros chatbots, como ELIZA (Weizenbaum, 1966), funcionaban mediante reconocimiento de patrones simples y sustitución de texto. Aunque podían simular conversación, no comprendían el significado real de las preguntas. Posteriormente, el desarrollo de modelos estadísticos y redes neuronales permitió incorporar mayor flexibilidad en la generación de respuestas.

Con la introducción de la arquitectura Transformer propuesta por Vaswani et al. (2017), se produjo un cambio significativo en el campo del PLN. Esta arquitectura permitió modelar dependencias contextuales dentro de grandes volúmenes de texto, facilitando el desarrollo de modelos de lenguaje de gran escala (Large Language Models, LLM). Dichos modelos son capaces de generar texto coherente, responder preguntas complejas y mantener consistencia temática a lo largo de múltiples turnos de conversación.

Brown et al. (2020) demostraron que los modelos de gran escala pueden desempeñarse en múltiples tareas sin requerir entrenamiento específico para cada una, fenómeno conocido como aprendizaje en contexto (in-context learning). Esta característica amplía considerablemente las posibilidades de implementación en sistemas conversacionales educativos.

3.2.1 LIMITACIONES DE LOS MODELOS GENERATIVOS SIN CONTEXTO EXTERNO

A pesar de sus avances, los modelos de lenguaje presentan limitaciones inherentes. Su funcionamiento se basa en la predicción probabilística de la siguiente palabra dentro de una secuencia, lo que implica que no poseen conocimiento estructurado en el sentido tradicional. Esto puede conducir a la generación de información incorrecta pero plausible, fenómeno comúnmente conocido como “alucinación” (Ji et al., 2023).

Además, los LLM poseen restricciones en la cantidad de texto que pueden procesar simultáneamente, conocida como ventana de contexto. Cuando se requiere manejar grandes volúmenes de información, como múltiples documentos institucionales o reglamentos extensos, enviar todo el contenido al modelo puede resultar ineficiente o técnicamente inviable.

En entornos académicos formales, donde la precisión y el respaldo documental son esenciales, estas limitaciones hacen necesario complementar la generación de lenguaje con mecanismos adicionales de recuperación estructurada de información.

3.3 MODELOS DE LENGUAJE DE GRAN ESCALA (LLM)

Los Modelos de Lenguaje de Gran Escala (Large Language Models, LLM) representan uno de los avances más significativos recientes en el campo de la inteligencia artificial aplicada al lenguaje. Estos modelos son sistemas entrenados con grandes volúmenes de datos textuales y diseñados para predecir secuencias lingüísticas de forma contextual. Su funcionamiento se basa principalmente en la arquitectura Transformer, la cual introdujo el mecanismo de atención (attention mechanism) para modelar relaciones entre palabras dentro de un mismo contexto (Vaswani et al., 2017).

A diferencia de modelos tradicionales basados en reglas o gramáticas predefinidas, los LLM aprenden patrones estadísticos a gran escala, lo que les permite generar texto coherente, resumir documentos, traducir contenido y responder preguntas abiertas. Brown et al. (2020) demostraron que estos modelos pueden adaptarse a múltiples tareas mediante simples instrucciones en lenguaje natural, sin requerir ajustes estructurales profundos. Esta capacidad ha ampliado considerablemente su aplicabilidad en sistemas conversacionales.

En el ámbito académico y educativo, los LLM pueden utilizarse como asistentes para generar explicaciones, responder consultas técnicas o resumir información extensa. Sin embargo, su utilidad depende en gran medida de la forma en que se integren dentro de arquitecturas controladas, especialmente cuando las respuestas deben basarse en fuentes específicas y verificables.

3.3.1 ARQUITECTURA TRANSFORMER Y MECANISMO DE ATENCIÓN

La arquitectura Transformer introducida por Vaswani et al. (2017) eliminó la necesidad de recurrir a modelos secuenciales tradicionales como las redes recurrentes (RNN), proponiendo en su lugar un mecanismo de atención capaz de evaluar simultáneamente las relaciones entre todos los elementos de una secuencia. Este enfoque mejora la capacidad del modelo para comprender dependencias largas dentro del texto.

El mecanismo de atención permite asignar distintos niveles de relevancia a cada palabra dentro de un contexto, facilitando la construcción de representaciones semánticas más precisas. Esta característica es clave en sistemas conversacionales, donde una pregunta puede depender de información mencionada anteriormente en la conversación.

No obstante, aunque los LLM manejan contexto interno dentro de una conversación limitada, no almacenan conocimiento estructurado persistente. Su "conocimiento" proviene del proceso de entrenamiento previo, no de una base de datos actualizada o dinámica.

3.3.2 VENTANA DE CONTEXTO Y ESCALABILIDAD

Uno de los aspectos técnicos relevantes en la implementación de LLM es la denominada ventana de contexto, que determina la cantidad máxima de tokens que el modelo puede procesar en una sola interacción. Cuando la información requerida supera este límite, es necesario resumir, fragmentar o seleccionar contenido antes de enviarlo al modelo.

En escenarios donde se manejan múltiples documentos académicos, reglamentos institucionales o manuales extensos, la ventana de contexto se convierte en un factor limitante. Enviar grandes cantidades de texto directamente al modelo no solo incrementa el costo computacional, sino que también puede afectar la precisión de las respuestas.

Esta restricción técnica conduce naturalmente a la necesidad de mecanismos que permitan recuperar únicamente la información relevante para cada consulta, en lugar de procesar el conjunto completo de documentos en cada interacción.

3.3.3 RIESGO DE ALUCINACIÓN Y NECESIDAD DE CONTROL

Diversos estudios recientes han señalado que los modelos generativos pueden producir respuestas incorrectas que aparentan ser coherentes y convincentes. Ji et al. (2023) describen este fenómeno como alucinación generativa, el cual ocurre cuando el modelo genera información no respaldada por datos verificables.

En aplicaciones académicas o institucionales, donde la precisión y el respaldo documental son fundamentales, este comportamiento representa un riesgo significativo. Un sistema robótico que actúe como asesor académico no puede basar sus respuestas en probabilidades estadísticas sin referencia a fuentes concretas.

Por esta razón, la implementación de LLM en entornos formales requiere integrar mecanismos que restrinjan o guíen su generación, permitiendo que las respuestas se fundamenten en información previamente validada y accesible de forma estructurada.

3.4 RECUPERACIÓN DE INFORMACIÓN Y BÚSQUEDA SEMÁNTICA

La recuperación de información (Information Retrieval, IR) constituye un área de estudio dedicada al desarrollo de métodos que permiten localizar contenido relevante dentro de grandes volúmenes de datos. Tradicionalmente, los sistemas de recuperación han operado mediante coincidencia exacta de palabras clave, utilizando estructuras como índices invertidos para localizar documentos que contengan determinados términos (Manning, Raghavan & Schütze, 2008).

Este enfoque basado en coincidencia léxica resulta adecuado cuando la consulta del usuario emplea exactamente los mismos términos presentes en el documento. Sin embargo, presenta limitaciones cuando la pregunta está formulada con sinónimos, variaciones lingüísticas o estructuras semánticamente equivalentes pero distintas en forma textual.

En entornos académicos, esta limitación es particularmente relevante. Una normativa puede contener el término "requisito de graduación", mientras que el usuario podría formular la pregunta como "¿Qué necesito para graduarme?". Aunque ambas expresiones comparten

intención semántica, un sistema basado únicamente en coincidencia literal podría no identificar la relación.

3.4.1 BÚSQUEDA LÉXICA VS. BÚSQUEDA SEMÁNTICA

La búsqueda léxica tradicional se fundamenta en la comparación directa de términos, frecuentemente utilizando métricas como TF-IDF (Term Frequency–Inverse Document Frequency). Si bien estas técnicas han demostrado eficacia durante décadas, no capturan plenamente el significado contextual de una consulta.

La búsqueda semántica, en cambio, busca representar el significado del texto en un espacio matemático donde fragmentos conceptualmente similares se encuentren próximos entre sí, incluso si no comparten las mismas palabras. Este cambio de paradigma ha sido posible gracias al desarrollo de representaciones distribuidas del lenguaje, como los embeddings (Mikolov et al., 2013).

En lugar de buscar coincidencias exactas, la búsqueda semántica evalúa la similitud entre vectores que representan tanto la consulta como los documentos disponibles. Esto permite recuperar información relevante aun cuando la redacción difiera significativamente.

3.4.2 LIMITACIONES DE LA RECUPERACIÓN TRADICIONAL EN ENTORNOS DINÁMICOS

Cuando se manejan múltiples documentos institucionales, reglamentos extensos o repositorios de información académica, depender únicamente de coincidencias literales puede conducir a resultados incompletos o imprecisos. Además, la creciente complejidad de los entornos digitales exige sistemas capaces de interpretar intención y contexto, no solo términos individuales.

Manning et al. (2008) señalan que los sistemas modernos de recuperación deben combinar eficiencia computacional con comprensión contextual. Esta necesidad se vuelve aún más evidente cuando dichos sistemas se integran con modelos generativos de lenguaje, ya que la calidad de la respuesta final depende directamente de la precisión del contenido recuperado.

En el contexto del presente proyecto, la recuperación de información no constituye un fin en sí mismo, sino un componente necesario para respaldar las respuestas generadas por el modelo conversacional. Por ello, resulta fundamental comprender los principios que permiten

representar texto de forma matemática y medir similitud semántica entre fragmentos documentales.

3.5 REPRESENTACIÓN VECTORIAL Y EMBEDDINGS

La representación del lenguaje en formato matemático ha sido uno de los avances más relevantes en el procesamiento moderno de texto. Tradicionalmente, el texto era tratado como una secuencia simbólica sin estructura numérica significativa. Sin embargo, los enfoques contemporáneos permiten transformar palabras, oraciones e incluso documentos completos en vectores dentro de espacios multidimensionales.

Estos vectores, conocidos como embeddings, representan el significado semántico de un fragmento de texto en forma numérica. La idea central consiste en que elementos lingüísticos con significados similares tienden a ubicarse próximos dentro de un espacio vectorial continuo. Este principio fue ampliamente difundido a partir de los modelos Word2Vec propuestos por Mikolov et al. (2013), los cuales demostraron que las relaciones semánticas entre palabras podían capturarse mediante operaciones matemáticas simples.

En un modelo basado en embeddings, cada palabra o fragmento textual se convierte en un punto dentro de un espacio de alta dimensión. La similitud entre dos textos puede estimarse mediante métricas como la distancia coseno, que mide el grado de alineación entre dos vectores. Cuanto menor sea la distancia, mayor será la similitud semántica entre los textos representados.

3.5.1 DE REPRESENTACIONES LOCALES A REPRESENTACIONES CONTEXTUALES

Los primeros modelos de embeddings asignaban un único vector fijo a cada palabra, independientemente del contexto en el que apareciera. Si bien este enfoque permitió capturar relaciones semánticas generales, presentaba limitaciones cuando una palabra tenía múltiples significados.

Con la aparición de modelos contextualizados basados en la arquitectura Transformer (Vaswani et al., 2017), los embeddings evolucionaron hacia representaciones dinámicas. En este esquema, el vector asociado a una palabra depende del contexto en el que se encuentra dentro de la oración. Esta característica mejora significativamente la precisión en tareas de búsqueda semántica y recuperación de información.

Devlin et al. (2019) introdujeron BERT (Bidirectional Encoder Representations from Transformers), uno de los primeros modelos ampliamente difundidos que generó representaciones contextuales profundas, permitiendo capturar relaciones complejas dentro del texto. Este avance consolidó el uso de embeddings no solo para clasificación o traducción, sino también para sistemas de recuperación semántica.

3.5.2 EMBEDDINGS A NIVEL DE DOCUMENTO

En aplicaciones donde se manejan documentos extensos, como reglamentos académicos o manuales institucionales, no basta con representar palabras individuales. Es necesario generar representaciones a nivel de oración, párrafo o fragmento de documento.

Reimers y Gurevych (2019) propusieron modelos como Sentence-BERT, diseñados específicamente para tareas de comparación semántica entre oraciones. Este tipo de representación permite calcular similitud entre una pregunta formulada por un usuario y distintos fragmentos documentales, facilitando la identificación de contenido relevante.

En sistemas académicos que requieren consultar múltiples fuentes escritas, la utilización de embeddings a nivel de fragmento resulta especialmente útil. En lugar de analizar todo el documento en su totalidad, el sistema puede dividir el texto en unidades más pequeñas y asignar a cada una una representación vectorial independiente. De esta forma, las consultas pueden relacionarse únicamente con los segmentos más pertinentes.

3.5.3 ROL DE LOS EMBEDDINGS EN SISTEMAS CONVERSACIONALES

Dentro de arquitecturas conversacionales avanzadas, los embeddings cumplen una función intermedia entre la consulta del usuario y la generación de la respuesta. Cuando el usuario formula una pregunta, esta se transforma en un vector que puede compararse matemáticamente con los vectores asociados a fragmentos documentales previamente indexados.

Este mecanismo permite recuperar información relevante antes de enviarla al modelo generativo. En consecuencia, el modelo no genera respuestas basadas únicamente en su conocimiento previo, sino apoyándose en contenido específico recuperado desde una fuente definida.

En el contexto del presente proyecto, la representación vectorial constituye un componente conceptual fundamental, ya que permite integrar documentos académicos dentro de un sistema conversacional robótico sin depender exclusivamente de coincidencias literales o reglas preprogramadas.

3.6 RECUPERACIÓN AUMENTADA POR GENERACIÓN (RAG)

La Recuperación Aumentada por Generación (Retrieval-Augmented Generation, RAG) es un enfoque híbrido que combina mecanismos de recuperación de información con modelos generativos de lenguaje. Su objetivo principal es mejorar la precisión y confiabilidad de las respuestas producidas por un modelo de lenguaje, incorporando información externa relevante en el momento de la generación.

Tradicionalmente, los modelos de lenguaje generativos producen respuestas basadas únicamente en los patrones aprendidos durante su entrenamiento. Aunque esta capacidad permite generar texto coherente, no garantiza que la información proporcionada sea específica, actualizada o verificable dentro de un dominio particular. Con el fin de reducir estas limitaciones, Lewis et al. (2020) propusieron una arquitectura en la que el modelo no solo genera texto, sino que primero consulta una fuente externa de conocimiento y utiliza el contenido recuperado como parte de su contexto.

Este enfoque resulta especialmente útil en entornos donde la información debe estar fundamentada en documentos específicos, como reglamentos académicos, manuales institucionales o normativas internas. En lugar de confiar únicamente en el conocimiento general del modelo, el sistema puede respaldar sus respuestas con fragmentos textuales previamente indexados.

3.6.1 ARQUITECTURA CONCEPTUAL DE RAG

El funcionamiento general de un sistema RAG puede describirse en las siguientes etapas:

1. El usuario formula una pregunta en lenguaje natural.
2. La pregunta se transforma en una representación vectorial mediante embeddings.
3. El sistema busca en una base indexada los fragmentos documentales más similares semánticamente.

4. Los fragmentos recuperados se incorporan como contexto adicional.
5. El modelo de lenguaje genera la respuesta basándose tanto en la pregunta como en el contenido recuperado.

De esta forma, el proceso de generación no parte únicamente de probabilidades lingüísticas generales, sino de información específica seleccionada previamente. Según Lewis et al. (2020), esta combinación mejora el rendimiento en tareas que requieren conocimiento intensivo y reduce la probabilidad de alucinaciones.

3.6.2 VENTAJAS DE RAG EN ENTORNOS ACADÉMICOS

En el contexto académico, donde la precisión y el respaldo documental son fundamentales, la arquitectura RAG ofrece varias ventajas:

- Permite trabajar con información institucional actualizable.
- Reduce la dependencia de conocimiento general del modelo.
- Mejora la trazabilidad de las respuestas generadas.
- Facilita la escalabilidad al incorporar nuevos documentos sin necesidad de reentrenar el modelo.

A diferencia de enfoques basados en entrenamiento adicional (*fine-tuning*), la incorporación de nuevos documentos en un sistema RAG no requiere modificar la arquitectura interna del modelo de lenguaje. Basta con indexar el nuevo contenido dentro del sistema de recuperación, lo cual resulta más eficiente y sostenible en entornos dinámicos.

3.6.3 RAG COMO ESTRATEGIA DE CONTROL DE DOMINIO

Uno de los principales desafíos de los sistemas generativos es el control de dominio. Cuando un modelo responde preguntas abiertas, puede extenderse hacia áreas no relacionadas con la fuente oficial de información. En un sistema institucional, esto podría resultar problemático si el robot proporciona respuestas fuera del marco normativo correspondiente.

La arquitectura RAG actúa como un mecanismo de restricción implícita. Al limitar el contexto de generación a fragmentos documentales específicos, el sistema reduce la probabilidad de desviaciones temáticas. Esto no elimina completamente el riesgo de errores, pero introduce una capa de control adicional que mejora la coherencia y la relevancia de las respuestas.

En el presente proyecto, la incorporación conceptual de RAG permite fundamentar la transición desde un robot basado en guiones predefinidos hacia una plataforma conversacional capaz de consultar múltiples documentos académicos y generar respuestas contextualizadas.

3.7 BASES DE DATOS VECTORIALES

El desarrollo de técnicas de representación vectorial y recuperación semántica dio origen a una necesidad estructural: almacenar, organizar y consultar grandes volúmenes de vectores de manera eficiente. Las bases de datos vectoriales surgen como una solución especializada para este propósito, permitiendo gestionar representaciones numéricas de texto y realizar búsquedas basadas en similitud.

A diferencia de las bases de datos relacionales tradicionales diseñadas para manejar estructuras tabulares y consultas exactas mediante lenguaje SQL, las bases vectoriales están optimizadas para operaciones de comparación geométrica entre vectores de alta dimensión. Estas comparaciones suelen realizarse mediante métricas como la similitud coseno o la distancia euclidiana, cuyo objetivo es identificar elementos semánticamente cercanos dentro de un espacio matemático.

Johnson, Douze y Jégou (2019) destacan que las búsquedas de vecinos más cercanos (*Approximate Nearest Neighbor Search, ANN*) se han convertido en un componente fundamental para aplicaciones de recuperación a gran escala. En lugar de comparar cada vector con todos los demás —lo cual sería computacionalmente costoso—, estos sistemas emplean estructuras de indexación especializadas que permiten acelerar significativamente la búsqueda.

3.7.1 DIFERENCIAS CON BASES DE DATOS RELACIONALES

Las bases de datos relacionales almacenan información estructurada en tablas y permiten ejecutar consultas determinísticas mediante operadores lógicos definidos. Este modelo resulta adecuado cuando los datos poseen una estructura fija y se requiere precisión en la coincidencia de campos específicos.

Sin embargo, cuando se trabaja con representaciones vectoriales del lenguaje, el objetivo no es encontrar coincidencias exactas, sino proximidad semántica. Esto implica operar en espacios

numéricos de alta dimensión, donde cada registro es un vector que puede contener cientos o miles de valores decimales.

En este sentido, las bases vectoriales no sustituyen necesariamente a las bases relacionales, sino que cumplen una función complementaria dentro de arquitecturas híbridas. Mientras la base relacional puede almacenar documentos, metadatos o registros institucionales, la base vectorial almacena las representaciones numéricas que permiten recuperar información por similitud conceptual.

3.7.2 INDEXACIÓN Y BÚSQUEDA DE VECINOS CERCANOS

El problema central que enfrentan las bases vectoriales es la búsqueda eficiente del vector más similar a una consulta dada. Este problema, conocido como búsqueda del vecino más cercano (*Nearest Neighbor Search*), se vuelve complejo cuando el número de vectores almacenados es elevado.

Para abordar este desafío, se emplean técnicas de búsqueda aproximada que reducen el costo computacional sin sacrificar significativamente la precisión. Johnson et al. (2019) describen cómo bibliotecas como FAISS implementan estructuras de indexación que permiten consultas en tiempos razonables incluso con millones de vectores.

Además de FAISS, han surgido herramientas especializadas como Chroma, Pinecone y Weaviate, diseñadas para integrarse con modelos de lenguaje modernos y facilitar la implementación de arquitecturas basadas en recuperación semántica. Estas soluciones permiten almacenar fragmentos documentales junto con sus embeddings, establecer metadatos y realizar búsquedas por similitud de manera programática.

3.7.3 ROL DE LAS BASES VECTORIALES EN ARQUITECTURAS RAG

Dentro de un sistema basado en Recuperación Aumentada por Generación, la base de datos vectorial actúa como repositorio intermedio entre la consulta del usuario y el modelo generativo. Cuando una pregunta es transformada en embedding, este vector se compara con los embeddings previamente almacenados. Los fragmentos con mayor similitud son seleccionados y utilizados como contexto para la generación final de la respuesta.

Este mecanismo permite trabajar con múltiples documentos académicos, manuales o reglamentos sin necesidad de cargar la totalidad del contenido en cada interacción. Además,

facilita la actualización incremental del sistema: nuevos documentos pueden fragmentarse, convertirse en embeddings e incorporarse a la base vectorial sin alterar la estructura general del modelo.

En el marco conceptual del presente proyecto, las bases vectoriales representan el componente que hace viable la consulta semántica sobre información institucional extensa. Su inclusión dentro de la arquitectura no responde únicamente a una decisión técnica, sino a la necesidad de garantizar escalabilidad, precisión y sostenibilidad en el tiempo.


3.8 INTEGRACIÓN DE ARQUITECTURAS CONVERSACIONALES EN SISTEMAS ROBÓTICOS EDUCATIVOS

La integración de modelos de lenguaje y mecanismos de recuperación semántica dentro de sistemas robóticos educativos representa una evolución natural en el desarrollo de plataformas inteligentes. Mientras que los primeros robots implementados en entornos académicos se apoyaban en secuencias programadas y respuestas predeterminadas, las arquitecturas conversacionales actuales permiten ampliar significativamente su capacidad de interacción.

Desde el punto de vista arquitectónico, la integración de un modelo de lenguaje dentro de un sistema robótico implica coordinar múltiples componentes: reconocimiento de entrada (ya sea mediante voz o texto), procesamiento semántico, recuperación de información relevante, generación de respuesta y conversión de salida en formato audible o visual. Cada uno de estos módulos debe operar de forma sincronizada para garantizar coherencia y fluidez en la interacción.

En este tipo de arquitecturas, el robot deja de ser únicamente un ejecutor de movimientos físicos y se convierte en una interfaz tangible de un sistema cognitivo más amplio. Es decir, la inteligencia no reside exclusivamente en la estructura mecánica del robot, sino en la arquitectura conversacional que lo respalda. De acuerdo con Breazeal (2003), los robots sociales efectivos son aquellos que combinan capacidades físicas con procesos internos capaces de interpretar y responder al entorno de forma contextual.

Ilustración 1-Arquitectura conceptual del sistema



Fuente: (Propia del autor)

3.8.1 ARQUITECTURA MODULAR Y SEPARACIÓN DE RESPONSABILIDADES

Un principio fundamental en la integración de sistemas complejos es la modularidad. La separación de responsabilidades permite que cada componente cumpla una función específica sin comprometer la estabilidad del sistema completo.

En una arquitectura conversacional aplicada a robótica educativa, pueden identificarse al menos los siguientes módulos conceptuales:

- Módulo de entrada: recibe la consulta del usuario.
- Módulo de representación semántica: transforma la entrada en embedding.
- Módulo de recuperación: consulta la base vectorial para obtener fragmentos relevantes.
- Módulo generativo: produce la respuesta utilizando el contexto recuperado.
- Módulo de salida: transforma el texto generado en voz o señal comprensible para el usuario.

Este enfoque modular no solo mejora la claridad del diseño, sino que facilita futuras mejoras, como el reemplazo del modelo generativo, la actualización de documentos indexados o la incorporación de nuevos mecanismos de validación.

3.8.2 CONSIDERACIONES DE ESCALABILIDAD Y MANTENIMIENTO

En entornos institucionales, los reglamentos, lineamientos académicos y normativas pueden modificarse periódicamente. Por esta razón, una arquitectura rígida basada en guiones predefinidos requeriría actualizaciones manuales constantes, lo cual dificulta el mantenimiento.

La adopción de arquitecturas basadas en recuperación semántica permite desacoplar el conocimiento documental del modelo generativo. Cuando un nuevo documento se incorpora al sistema, basta con procesarlo, fragmentarlo e indexarlo en la base vectorial para que pueda ser consultado automáticamente. Este mecanismo reduce la necesidad de reentrenamiento y mejora la sostenibilidad del sistema en el tiempo.

Además, la incorporación de mecanismos de recuperación previos a la generación permite establecer una capa adicional de control, lo cual es particularmente relevante en sistemas académicos donde la exactitud y la formalidad de las respuestas son esenciales.

3.8.3 APLICACIÓN CONCEPTUAL AL PRESENTE PROYECTO

En el contexto del presente trabajo, la integración de una arquitectura conversacional basada en recuperación semántica dentro de un sistema robótico educativo permite superar las limitaciones de los enfoques tradicionales basados en secuencias estáticas.

El robot no opera únicamente como un expositor programado, sino como una interfaz interactiva capaz de interpretar preguntas abiertas y consultar información institucional de manera estructurada. Esta evolución transforma el sistema en una plataforma adaptable, escalable y alineada con las necesidades reales del entorno académico.

De esta manera, los fundamentos teóricos abordados en las secciones anteriores (robótica humanoide, procesamiento del lenguaje natural, modelos generativos, recuperación

semántica, embeddings y bases vectoriales) convergen en una arquitectura integrada que sustenta técnicamente la propuesta desarrollada en el presente proyecto.

3.9 LIMITACIONES DE LOS ENFOQUES ANALIZADOS

A pesar de las ventajas que ofrecen los modelos de lenguaje de gran escala y las arquitecturas basadas en Recuperación Aumentada por Generación (RAG), su implementación presenta ciertas limitaciones técnicas, operativas y metodológicas que deben considerarse durante el desarrollo del sistema. Estas limitaciones se relacionan con factores como la dependencia de servicios externos para el procesamiento de lenguaje natural, las restricciones inherentes a los modelos generativos, la disponibilidad y actualización de los documentos institucionales utilizados como base de conocimiento, así como las condiciones de prueba del sistema y las capacidades del hardware disponible. La Tabla 1 resume las principales limitaciones identificadas en el contexto del presente proyecto y su posible impacto en el funcionamiento del sistema.

Tabla 1-Limitaciones técnicas y operativas del sistema propuesto

Tipo	Limitación	Impacto
Técnica	Dependencia de API externa de LLM	Posible latencia
Técnica	Ventana de contexto del modelo	No permite procesar grandes volúmenes de texto simultáneamente
Datos	Dependencia de documentos institucionales actuales	Si los documentos cambian, requiere reindexación
Muestra	Tamaño reducido de estudiantes en pruebas	Resultados con limitada capacidad de generalización
Hardware	Capacidad de procesamiento del equipo local	Puede limitar la escalabilidad del sistema

Fuente: (Propia del autor)

IV. METODOLOGÍA

4.1 ENFOQUE

El presente proyecto se desarrolló bajo un enfoque metodológico de tipo mixto, combinando elementos cualitativos y cuantitativos para el análisis, diseño e implementación de la arquitectura conversacional propuesta. Este enfoque permitió abordar el problema desde una perspectiva técnica y funcional, considerando tanto la construcción del sistema como la evaluación de su comportamiento en un entorno real de interacción con usuarios.

Desde el enfoque cualitativo, se analizó la arquitectura actual del robot humanoide ADAI y los procesos de interacción existentes, identificando las limitaciones presentes en el sistema basado en secuencias predefinidas. Este análisis permitió definir los requerimientos necesarios para la integración de un modelo conversacional basado en Recuperación Aumentada por Generación (RAG), así como establecer los componentes arquitectónicos necesarios para su funcionamiento.

Por otra parte, el enfoque cuantitativo se aplicó durante la fase de validación del sistema, donde se evaluó el desempeño del prototipo mediante pruebas controladas con consultas académicas realizadas por estudiantes. En esta etapa se midieron indicadores como la precisión de las respuestas generadas, la coherencia contextual y la capacidad del sistema para recuperar información relevante a partir de documentos institucionales.

La combinación de ambos enfoques permitió no solo diseñar la arquitectura conversacional propuesta, sino también evaluar su funcionamiento dentro del contexto académico para el cual fue concebida. De esta manera, el enfoque metodológico adoptado facilitó el análisis integral del problema y la validación técnica del sistema desarrollado.

4.2 VARIABLES DE INVESTIGACIÓN

Las variables consideradas se enfocan en evaluar la calidad de las respuestas generadas por el sistema durante la interacción con estudiantes universitarios. Para ello, se analizaron aspectos relacionados con la precisión de la información proporcionada, la coherencia de las respuestas generadas y la percepción de los usuarios respecto al funcionamiento del sistema.

A continuación, se describen las principales variables consideradas durante la investigación:

- Precisión de respuesta: Se refiere al grado en que las respuestas generadas por el sistema corresponden correctamente a la información contenida en los documentos académicos institucionales utilizados como base de conocimiento.
- Tiempo de respuesta: Corresponde al intervalo de tiempo que transcurre entre la formulación de una consulta por parte del estudiante y la generación de la respuesta por parte del sistema.
- Satisfacción del usuario: Hace referencia a la percepción de los estudiantes respecto a la utilidad, claridad y coherencia de las respuestas proporcionadas por el robot humanoide ADAI.

Estas variables permiten analizar de manera integral el desempeño del sistema propuesto, proporcionando indicadores que facilitan la evaluación de su efectividad como asesor académico inteligente dentro del entorno universitario.

4.3 TÉCNICAS E INSTRUMENTOS APLICADOS

Durante el desarrollo del presente proyecto se utilizaron distintas técnicas e instrumentos tecnológicos que permitieron diseñar, implementar y evaluar la arquitectura conversacional propuesta. Estas herramientas facilitaron tanto el procesamiento de información textual como la generación de respuestas mediante modelos de lenguaje y mecanismos de recuperación semántica.

Las técnicas empleadas se enfocaron principalmente en el procesamiento de lenguaje natural, recuperación semántica de información y evaluación del sistema mediante interacción con usuarios reales. A continuación, se describen las principales herramientas y tecnologías utilizadas durante el desarrollo del proyecto.

4.3.1 MODELOS DE LENGUAJE DE GRAN ESCALA (LLM)

Los modelos de lenguaje de gran escala (Large Language Models, LLM) constituyen uno de los componentes fundamentales en la arquitectura conversacional implementada en este proyecto. Estos modelos están diseñados para comprender y generar lenguaje natural mediante el análisis de grandes volúmenes de texto durante su fase de entrenamiento, lo que les permite producir respuestas coherentes a consultas formuladas por los usuarios.

El funcionamiento de los LLM se basa principalmente en la arquitectura Transformer, la cual utiliza mecanismos de atención para identificar relaciones contextuales entre palabras dentro de una secuencia textual. Este enfoque permite que el modelo procese información de manera paralela y capture dependencias semánticas complejas dentro del lenguaje (Vaswani et al., 2017).

En el contexto del presente proyecto, el modelo de lenguaje cumple la función de generar respuestas a partir de las consultas realizadas por los estudiantes. Sin embargo, en lugar de depender únicamente del conocimiento adquirido durante su entrenamiento, el modelo recibe información contextual proveniente de documentos institucionales previamente procesados mediante técnicas de recuperación semántica. Esta integración permite que las respuestas generadas estén fundamentadas en fuentes documentales específicas.

El uso de modelos de lenguaje en sistemas conversacionales ha demostrado ser altamente efectivo para aplicaciones de asistencia virtual, ya que permite interpretar preguntas formuladas en lenguaje natural y generar respuestas comprensibles para los usuarios. No obstante, diversos estudios han señalado que estos modelos pueden generar información incorrecta cuando operan sin acceso a fuentes externas verificables, fenómeno conocido como alucinación (Ji et al., 2023).

Por esta razón, en el presente proyecto el modelo de lenguaje fue integrado dentro de una arquitectura basada en Recuperación Aumentada por Generación (RAG), donde el modelo no responde únicamente con base en su conocimiento previo, sino apoyándose en fragmentos documentales recuperados dinámicamente desde una base de conocimiento institucional.

Esta combinación entre generación de lenguaje natural y recuperación de información permite mejorar la precisión de las respuestas y garantizar que la información proporcionada por el sistema esté alineada con la documentación académica oficial utilizada como fuente de conocimiento.

4.3.2 RECUPERACIÓN AUMENTADA POR GENERACIÓN (RAG)

La Recuperación Aumentada por Generación (Retrieval-Augmented Generation, RAG) es una técnica que combina mecanismos de recuperación de información con modelos generativos de lenguaje natural. Este enfoque permite mejorar la precisión de las respuestas generadas por un modelo de lenguaje al incorporar información proveniente de fuentes externas durante

el proceso de generación de texto. Según Lewis et al. (2020), los sistemas basados en RAG integran dos componentes principales: un módulo de recuperación que identifica información relevante dentro de una base de conocimiento y un modelo generativo encargado de producir la respuesta final utilizando dicho contenido como contexto.

En el presente proyecto, la arquitectura conversacional implementada para el robot humanoide ADAI se basó en este enfoque con el objetivo de permitir que el sistema pueda responder consultas académicas fundamentadas en documentos institucionales de la universidad. A diferencia de los sistemas conversacionales tradicionales que dependen únicamente del conocimiento interno del modelo de lenguaje, la arquitectura RAG permite consultar dinámicamente información contenida en una colección de documentos previamente procesados e indexados.

El funcionamiento general del sistema inicia cuando el usuario formula una consulta mediante interacción con el robot. Esta consulta es transformada en una representación vectorial utilizando modelos de embeddings. Posteriormente, el sistema realiza una búsqueda semántica dentro de una base de datos vectorial que contiene fragmentos de documentos institucionales previamente segmentados. El mecanismo de recuperación identifica los fragmentos de texto más relevantes para la consulta realizada.

Una vez recuperados los fragmentos documentales, estos se incorporan como contexto adicional dentro de la solicitud enviada al modelo de lenguaje. De esta manera, el modelo genera una respuesta tomando como referencia la información recuperada, lo que permite reducir el riesgo de generación de respuestas incorrectas o no fundamentadas.

El uso de RAG resulta particularmente adecuado para entornos académicos, donde es necesario garantizar que las respuestas proporcionadas por el sistema estén respaldadas por información oficial o documentación institucional. Al integrar mecanismos de recuperación semántica con modelos generativos de lenguaje, este enfoque permite mantener la flexibilidad de los sistemas conversacionales modernos sin perder control sobre las fuentes de información utilizadas para generar las respuestas.

Diversos estudios recientes han demostrado que los sistemas basados en RAG pueden mejorar significativamente la precisión y confiabilidad de los sistemas de respuesta automática en comparación con modelos generativos que operan sin acceso a bases de conocimiento

externas (Lewis et al., 2020). Por esta razón, esta técnica fue seleccionada como el núcleo arquitectónico del sistema desarrollado en el presente proyecto.

El funcionamiento general del sistema desarrollado sigue las siguientes etapas:

1. El estudiante formula una consulta al robot humanoide ADAI mediante lenguaje natural.
2. La consulta es transformada en una representación vectorial utilizando modelos de embeddings.
3. El sistema realiza una búsqueda semántica dentro de una base de datos vectorial.
4. Se recuperan los fragmentos documentales con mayor similitud semántica.
5. Los fragmentos recuperados se envían como contexto al modelo de lenguaje.
6. El modelo genera una respuesta basada en la información recuperada.

Este mecanismo permite mejorar la precisión de las respuestas generadas y reducir el riesgo de generación de información incorrecta o no fundamentada.

4.3.3 REPRESENTACIÓN VECTORIAL Y EMBEDDINGS

La representación vectorial del lenguaje constituye una técnica fundamental dentro de los sistemas modernos de recuperación semántica de información. Este enfoque consiste en transformar fragmentos de texto en vectores numéricos dentro de un espacio matemático multidimensional, permitiendo comparar su similitud semántica mediante operaciones matemáticas. De esta manera, textos que poseen significados similares tienden a ubicarse cercanos entre sí dentro del espacio vectorial (Mikolov et al., 2013).

Los vectores generados a partir de texto son conocidos como embeddings. Estos representan características semánticas del lenguaje que permiten capturar relaciones entre palabras, oraciones o documentos completos. A diferencia de los métodos tradicionales de búsqueda basados únicamente en coincidencias exactas de palabras clave, los embeddings permiten identificar similitudes conceptuales entre distintos textos incluso cuando utilizan vocabulario diferente.

En el contexto del presente proyecto, los documentos académicos institucionales utilizados como base de conocimiento fueron procesados y divididos en fragmentos de menor tamaño

con el objetivo de facilitar su análisis y recuperación posterior. Cada uno de estos fragmentos fue transformado en una representación vectorial utilizando modelos de embeddings especializados en procesamiento de lenguaje natural.

Cuando un estudiante realiza una consulta al robot humanoide ADAI, dicha consulta también es convertida en un vector dentro del mismo espacio semántico. Posteriormente, el sistema compara este vector con los vectores asociados a los fragmentos documentales almacenados en la base de conocimiento. Esta comparación permite identificar los fragmentos que presentan mayor similitud semántica con la consulta realizada.

La similitud entre vectores suele calcularse mediante métricas matemáticas como la distancia coseno, la cual mide el grado de alineación entre dos vectores dentro del espacio multidimensional. Cuando la distancia entre vectores es menor, significa que los textos representados poseen mayor similitud conceptual.

El uso de embeddings en sistemas conversacionales ha demostrado ser especialmente efectivo en aplicaciones que requieren recuperación de información contextual. Según Devlin et al. (2019), las representaciones vectoriales contextuales permiten capturar relaciones semánticas complejas dentro del lenguaje, mejorando significativamente el desempeño de los sistemas de búsqueda semántica y recuperación de información.

En el sistema desarrollado en este proyecto, la utilización de embeddings permitió establecer el puente entre las consultas formuladas por los estudiantes y los fragmentos documentales disponibles dentro de la base de conocimiento institucional, facilitando así el funcionamiento del mecanismo de recuperación semántica utilizado dentro de la arquitectura RAG.

4.3.4 BASES DE DATOS VECTORIALES

Las bases de datos vectoriales constituyen una tecnología especializada diseñada para almacenar y consultar representaciones vectoriales de datos, particularmente utilizadas en aplicaciones que involucran procesamiento de lenguaje natural, búsqueda semántica y sistemas de recomendación. A diferencia de las bases de datos relacionales tradicionales, las bases de datos vectoriales están optimizadas para realizar búsquedas de similitud entre vectores de alta dimensión, permitiendo identificar rápidamente los elementos más cercanos a una consulta determinada (Manning, Raghavan & Schütze, 2008).

En el contexto de sistemas basados en recuperación semántica, las bases de datos vectoriales almacenan los embeddings generados a partir de documentos, oraciones o fragmentos textuales. Cada fragmento de texto es representado como un vector dentro de un espacio multidimensional y posteriormente indexado para facilitar su recuperación eficiente durante el proceso de búsqueda.

En el presente proyecto, los documentos académicos institucionales utilizados como base de conocimiento fueron segmentados en múltiples fragmentos de texto. Cada uno de estos fragmentos fue transformado en un embedding mediante modelos de representación vectorial, y posteriormente almacenado dentro de una base de datos vectorial. Este procedimiento permitió construir un repositorio estructurado que facilita la recuperación semántica de información relevante durante las consultas realizadas por los usuarios.

Dentro de la arquitectura del sistema, la base de datos vectorial cumple las siguientes funciones principales:

- almacenamiento de embeddings generados a partir de documentos institucionales
- indexación de vectores para facilitar la búsqueda eficiente
- recuperación de fragmentos documentales relevantes
- soporte para algoritmos de búsqueda de vecinos más cercanos

Cuando un estudiante realiza una pregunta al robot humanoide ADAI, el sistema convierte la consulta en un vector dentro del mismo espacio semántico en el que se encuentran representados los documentos almacenados. Posteriormente, la base de datos vectorial ejecuta un proceso de búsqueda conocido como búsqueda de vecinos más cercanos (Nearest Neighbor Search), el cual identifica los fragmentos de texto que presentan mayor similitud con la consulta formulada.

Este proceso permite recuperar únicamente los fragmentos documentales más relevantes para la pregunta realizada, evitando la necesidad de enviar grandes volúmenes de texto al modelo de lenguaje. De esta manera, el sistema logra mejorar tanto la eficiencia computacional como la precisión de las respuestas generadas.

El uso de bases de datos vectoriales resulta especialmente adecuado en arquitecturas basadas en Recuperación Aumentada por Generación, ya que permite integrar mecanismos eficientes

de recuperación semántica dentro del flujo de generación de respuestas. Según Johnson, Douze y Jégou (2019), las técnicas modernas de búsqueda de similitud en espacios vectoriales permiten manejar grandes volúmenes de información manteniendo tiempos de respuesta adecuados para aplicaciones interactivas.

En el sistema implementado en este proyecto, la base de datos vectorial actúa como el componente encargado de almacenar y recuperar los fragmentos documentales más relevantes para cada consulta realizada por los estudiantes, proporcionando el contexto necesario para que el modelo de lenguaje genere respuestas fundamentadas en información institucional verificable.

4.3.5 PRUEBAS CON USUARIOS Y ENCUESTAS DE SATISFACCIÓN

La evaluación de sistemas interactivos basados en inteligencia artificial requiere considerar no solo el desempeño técnico del sistema, sino también la experiencia de los usuarios que interactúan con él. En entornos educativos, donde los sistemas conversacionales buscan apoyar procesos de consulta o asesoría académica, resulta fundamental analizar la percepción de los estudiantes respecto a la utilidad, claridad y confiabilidad de las respuestas proporcionadas por el sistema (Nielsen, 1993).

En el presente proyecto, la validación del sistema desarrollado se realizó mediante pruebas controladas con estudiantes universitarios que interactuaron directamente con el robot humanoide ADAI. Durante estas pruebas, los participantes formularon diversas consultas relacionadas con información académica institucional, permitiendo evaluar el comportamiento del sistema en un contexto real de uso.

Las pruebas se diseñaron con el objetivo de observar cómo el sistema responde a diferentes tipos de preguntas formuladas en lenguaje natural. Asimismo, se buscó identificar posibles limitaciones en la recuperación de información, coherencia de las respuestas generadas y tiempo de procesamiento del sistema durante la interacción.

Adicionalmente, se aplicó un instrumento de recolección de información basado en encuestas de satisfacción dirigidas a los estudiantes participantes. Estas encuestas permitieron recopilar opiniones sobre distintos aspectos del sistema, tales como la claridad de las respuestas proporcionadas por el robot, la facilidad de interacción durante la conversación y la percepción general de utilidad del sistema como herramienta de apoyo académico.

Las encuestas constituyen una técnica ampliamente utilizada en investigaciones relacionadas con interacción humano-computadora, ya que permiten obtener información directa sobre la experiencia del usuario durante la interacción con un sistema tecnológico. Según Brooke (1996), los instrumentos de evaluación basados en percepción del usuario permiten complementar los indicadores técnicos del sistema, proporcionando una visión más completa de su desempeño.

Los datos obtenidos durante las pruebas y encuestas fueron posteriormente analizados con el propósito de evaluar el funcionamiento del sistema desarrollado y determinar su viabilidad como herramienta de asesoría académica dentro del entorno universitario. A partir de estos resultados fue posible identificar fortalezas, limitaciones y posibles mejoras futuras en la arquitectura conversacional implementada en el robot humanoide ADAI.

4.4 MATERIALES

Para el desarrollo del presente proyecto fue necesario utilizar distintos recursos tecnológicos que permitieron implementar, integrar y evaluar la arquitectura conversacional propuesta. Estos materiales incluyen dispositivos físicos, plataformas de software y herramientas de desarrollo utilizadas durante la implementación del sistema.

Los materiales utilizados se clasifican en tres categorías principales: hardware, software y herramientas adicionales.

4.4.1 HARDWARE

El desarrollo e implementación del sistema requirió el uso de distintos componentes de hardware que permitieron ejecutar los procesos de interacción, procesamiento y prueba del sistema conversacional.

Los principales dispositivos utilizados fueron los siguientes:

- Robot humanoide ADAI (InMoov): constituye la plataforma robótica utilizada para la interacción con los estudiantes. Este robot permite la integración de sistemas de procesamiento de lenguaje natural con mecanismos de interacción física y verbal dentro del entorno educativo.
- Computadora de desarrollo y procesamiento: equipo utilizado para el desarrollo del sistema, ejecución del backend conversacional y procesamiento de consultas

realizadas por los usuarios. Este dispositivo permitió ejecutar los componentes de recuperación semántica, generación de embeddings y comunicación con el modelo de lenguaje.

- Dispositivos de entrada y salida de audio: incluyen micrófono y sistema de reproducción de audio utilizados para permitir la interacción verbal entre los estudiantes y el robot durante las pruebas realizadas.
- Computadora personal de desarrollo: Se utilizó una computadora con procesador Intel Core i7 de 12^a generación, 32 GB de memoria RAM y tarjeta gráfica NVIDIA GeForce RTX 4070 con 12 GB de VRAM.

El conjunto de dispositivos de hardware utilizados permitió establecer la infraestructura física necesaria para la ejecución y evaluación del sistema conversacional desarrollado.

4.4.2 SOFTWARE

El desarrollo del sistema conversacional requirió el uso de diversas plataformas de software orientadas al procesamiento de lenguaje natural, recuperación semántica de información y desarrollo de aplicaciones basadas en inteligencia artificial. Estas herramientas permitieron implementar la arquitectura basada en Recuperación Aumentada por Generación (RAG) integrada al robot humanoide ADAI.

Las principales tecnologías de software utilizadas durante el desarrollo del proyecto fueron las siguientes:

- Python: fue el lenguaje de programación principal utilizado para el desarrollo del sistema. Este lenguaje es ampliamente utilizado en aplicaciones de inteligencia artificial y ciencia de datos debido a su simplicidad sintáctica, gran cantidad de bibliotecas disponibles y facilidad para integrar distintos componentes dentro de un mismo sistema (Van Rossum & Drake, 2009).
- API de OpenAI: utilizada para acceder a modelos de lenguaje de gran escala capaces de interpretar consultas formuladas por los estudiantes y generar respuestas en lenguaje natural. Los modelos generativos modernos permiten comprender preguntas formuladas en lenguaje natural y producir respuestas coherentes mediante el uso de arquitecturas basadas en Transformers (Brown et al., 2020).

- ChromaDB: base de datos vectorial diseñada para almacenar representaciones vectoriales de texto y realizar búsquedas semánticas basadas en similitud entre vectores. Este tipo de sistemas permite recuperar fragmentos documentales relevantes mediante algoritmos de búsqueda de vecinos cercanos, lo cual resulta fundamental para arquitecturas basadas en recuperación de información (Johnson, Douze & Jégou, 2019).
- Modelos de embeddings: se utilizaron para transformar tanto los documentos institucionales como las consultas realizadas por los estudiantes en representaciones vectoriales dentro de un espacio semántico multidimensional. Estas representaciones permiten comparar similitud conceptual entre distintos fragmentos de texto y recuperar información relevante durante las consultas realizadas por los usuarios (Mikolov et al., 2013).
- Procesamiento de documentos (chunking de texto): técnica utilizada para mejorar la recuperación de información, los documentos institucionales fueron divididos en fragmentos de menor tamaño antes de generar sus representaciones vectoriales. Este proceso, conocido como segmentación o *chunking*, permite indexar partes específicas del documento y facilita la recuperación de fragmentos relevantes durante la búsqueda semántica (Manning, Raghavan & Schütze, 2008).
- Librerías de procesamiento de lenguaje natural: se utilizaron diversas bibliotecas de procesamiento de lenguaje natural para facilitar el manejo de texto, la generación de embeddings y la integración de los distintos componentes del sistema. Las bibliotecas especializadas permiten implementar tareas como tokenización, transformación de texto y procesamiento semántico dentro de aplicaciones conversacionales (Jurafsky & Martin, 2021).

Estas herramientas de software permitieron implementar la arquitectura conversacional basada en RAG, integrando procesamiento de lenguaje natural, recuperación semántica de información y generación automática de respuestas dentro del sistema desarrollado.

4.4.3 HERRAMIENTAS ADICIONALES

Además de los recursos principales de hardware y software, durante el desarrollo del proyecto se utilizaron diversas herramientas que facilitaron el proceso de programación, depuración y gestión del código fuente.

Entre las herramientas utilizadas se encuentran:

- Cursor: editor de código basado en inteligencia artificial utilizado durante el desarrollo del sistema. Esta herramienta facilitó la programación mediante asistencia en generación de código, refactorización y exploración del proyecto.
- Git y GitHub: utilizados para el control de versiones del código fuente y la gestión del repositorio del proyecto, permitiendo mantener un historial de cambios y facilitar la organización del desarrollo.
- Herramientas de pruebas y depuración: utilizadas para verificar el funcionamiento del sistema conversacional, identificar errores durante el desarrollo y evaluar el comportamiento del sistema durante las pruebas realizadas con estudiantes.

El uso conjunto de estos materiales permitió implementar y evaluar la arquitectura conversacional propuesta, facilitando la integración de los diferentes componentes tecnológicos necesarios para el funcionamiento del sistema desarrollado.

4.5 METODOLOGÍA DE ESTUDIO

La metodología de estudio utilizada en el presente proyecto se basó en un enfoque de desarrollo incremental, el cual consiste en construir el sistema mediante una serie de iteraciones o incrementos funcionales. En cada incremento se desarrolla, integra y evalúa una parte del sistema hasta alcanzar la funcionalidad completa del proyecto. Este enfoque permite entregar componentes funcionales del sistema de manera progresiva, facilitando la identificación temprana de errores y la mejora continua del diseño durante el proceso de desarrollo (Pressman & Maxim, 2020).

El desarrollo incremental es ampliamente utilizado en proyectos de ingeniería de software debido a su capacidad para reducir riesgos durante el desarrollo y permitir una integración gradual de los diferentes módulos del sistema. En lugar de desarrollar el sistema completo en una única etapa, cada incremento introduce nuevas funcionalidades que se integran con las

previamente implementadas, permitiendo validar el comportamiento del sistema de forma progresiva (Sommerville, 2016).

En el contexto del presente proyecto, este enfoque permitió construir gradualmente la arquitectura conversacional basada en Recuperación Aumentada por Generación (RAG) integrada al robot humanoide ADAI. Cada incremento del sistema correspondió a una fase específica del proceso de desarrollo, lo que permitió validar individualmente los distintos componentes que conforman la arquitectura conversacional antes de su integración final.

A continuación, se describen las principales fases metodológicas seguidas durante la implementación del proyecto.

4.5.1 ANÁLISIS DEL SISTEMA EXISTENTE

La primera fase del proyecto consistió en analizar el funcionamiento actual del robot humanoide ADAI y su mecanismo de generación de respuestas. En esta etapa se estudiaron los componentes que conforman el sistema, incluyendo los módulos de interacción con el usuario, el procesamiento de consultas y la integración con modelos de lenguaje.

El análisis de sistemas existentes constituye una etapa fundamental dentro del proceso de desarrollo de software, ya que permite comprender la arquitectura actual del sistema y detectar limitaciones que deben ser abordadas en versiones futuras.

Durante este análisis se identificaron las principales limitaciones del enfoque utilizado anteriormente, particularmente la dependencia del envío completo de documentos como contexto al modelo de lenguaje. Esta estrategia presentaba dificultades cuando se trabajaba con múltiples documentos o grandes volúmenes de información.

El análisis realizado permitió establecer los requerimientos necesarios para diseñar una arquitectura conversacional más eficiente, basada en mecanismos de recuperación semántica de información.

4.5.2 DISEÑO DE LA ARQUITECTURA CONVERSACIONAL

Una vez identificadas las limitaciones del sistema existente, se procedió al diseño de la arquitectura conversacional propuesta para el proyecto.

El diseño arquitectónico constituye una etapa clave dentro del desarrollo de sistemas de software, ya que permite definir la organización general del sistema y la forma en que los distintos componentes interactúan entre sí (Pressman & Maxim, 2020).

En esta etapa se definieron los componentes principales del sistema, los cuales incluyen:

- módulo de interacción con el usuario mediante el robot ADAI
- modelo de lenguaje encargado de generar respuestas
- sistema de recuperación semántica basado en embeddings
- base de datos vectorial para almacenamiento de documentos
- flujo de integración basado en la arquitectura RAG

El diseño arquitectónico permitió establecer la forma en que cada componente del sistema se comunica con los demás, así como el flujo de información que sigue una consulta desde que es realizada por el usuario hasta que se genera la respuesta final.

4.5.3 PROCESAMIENTO E INDEXACIÓN DE DOCUMENTOS

La tercera fase del proyecto consistió en preparar los documentos académicos institucionales que serían utilizados como base de conocimiento para el sistema.

Durante esta etapa se realizaron las siguientes actividades:

- recopilación de documentos académicos institucionales relevantes
- segmentación de documentos en fragmentos de menor tamaño (chunking)
- generación de embeddings para cada fragmento textual
- almacenamiento de las representaciones vectoriales dentro de la base de datos vectorial

El procesamiento y preparación de datos constituye una etapa fundamental en sistemas basados en recuperación de información, ya que permite estructurar el conocimiento de manera que pueda ser consultado eficientemente durante la ejecución del sistema (Manning, Raghavan & Schütze, 2008).

Este proceso permitió construir una base de conocimiento estructurada que facilita la recuperación semántica de información durante las consultas realizadas por los usuarios.

4.5.4 IMPLEMENTACIÓN DEL SISTEMA RAG

Una vez preparada la base de conocimiento, se procedió a implementar el mecanismo de Recuperación Aumentada por Generación (RAG).

Durante esta fase se desarrolló el flujo completo de procesamiento de consultas, el cual incluye:

1. Recepción de la consulta formulada por el usuario
2. Generación del embedding correspondiente a la consulta
3. Búsqueda semántica en la base de datos vectorial
4. Recuperación de fragmentos documentales relevantes
5. Generación de la respuesta utilizando el modelo de lenguaje

Los sistemas basados en recuperación aumentada combinan técnicas de recuperación de información con modelos generativos de lenguaje para mejorar la precisión de las respuestas generadas, permitiendo que el modelo utilice información externa como contexto durante el proceso de generación (Lewis et al., 2020).

Este proceso permite que las respuestas generadas por el sistema estén fundamentadas en la información contenida en los documentos institucionales utilizados como fuente de conocimiento.

4.5.5 INTEGRACIÓN CON EL ROBOT HUMANOIDE ADAI

En esta etapa se integró el sistema conversacional desarrollado con el robot humanoide ADAI, permitiendo que las consultas realizadas por los estudiantes puedan ser procesadas por la arquitectura RAG implementada.

Esta integración permitió conectar los módulos de interacción del robot con el sistema de procesamiento de lenguaje natural, permitiendo que el robot actúe como interfaz física para el sistema de asesoría académica.

4.5.6 PRUEBAS DEL SISTEMA CON ESTUDIANTES

La última fase del desarrollo consistió en realizar pruebas controladas con estudiantes universitarios con el objetivo de evaluar el funcionamiento del sistema en un escenario real de interacción.

Durante estas pruebas los estudiantes realizaron consultas relacionadas con información académica institucional, permitiendo evaluar aspectos como:

- precisión de las respuestas generadas
- tiempo de respuesta del sistema
- claridad de la información proporcionada

Los resultados obtenidos durante esta fase permitieron analizar el desempeño del sistema y determinar su viabilidad como herramienta de asesoría académica dentro del entorno universitario.

4.6 METODOLOGÍA DE VALIDACIÓN

La validación del sistema desarrollado se realizó mediante un proceso de evaluación orientado a analizar el desempeño del asesor académico implementado en el robot humanoide ADAI. Esta validación tuvo como objetivo determinar si la arquitectura conversacional basada en Recuperación Aumentada por Generación (RAG) permite responder de manera adecuada a consultas académicas realizadas por estudiantes universitarios.

La evaluación de sistemas conversacionales requiere considerar tanto métricas técnicas del sistema como la experiencia de los usuarios que interactúan con él. En el contexto de sistemas de preguntas y respuestas basados en procesamiento de lenguaje natural, es común evaluar aspectos como la precisión de las respuestas, el tiempo de respuesta del sistema y la percepción de los usuarios respecto a la utilidad del sistema (Jurafsky & Martin, 2021).

Para validar el funcionamiento del sistema se realizaron pruebas controladas con estudiantes que interactuaron directamente con el robot. Estas pruebas permitieron evaluar el comportamiento del sistema en un escenario real de uso dentro del entorno universitario.

La metodología de validación se basó en la medición de distintos indicadores que permiten analizar el desempeño del sistema conversacional. Entre los principales aspectos evaluados se

encuentran la precisión de las respuestas generadas, el tiempo de respuesta del sistema y la percepción de los usuarios respecto a la utilidad del sistema como herramienta de asesoría académica.

A continuación, se describen los métodos utilizados para validar el sistema desarrollado.

4.6.1 EVALUACIÓN DE PRECISIÓN DE RESPUESTAS

La precisión de las respuestas generadas por el sistema se evaluó analizando si la información proporcionada por el robot correspondía correctamente al contenido de los documentos académicos institucionales utilizados como base de conocimiento.

Durante las pruebas realizadas, los estudiantes formularon diversas consultas relacionadas con información académica. Posteriormente, las respuestas generadas por el sistema fueron analizadas para determinar si se encontraban correctamente fundamentadas en la documentación utilizada por el sistema RAG.

Este análisis permitió identificar el grado de correspondencia entre las consultas realizadas y la información recuperada desde la base de conocimiento.

4.6.2 MEDICIÓN DEL TIEMPO DE RESPUESTA

Otro aspecto evaluado durante el proceso de validación fue el tiempo de respuesta del sistema. Esta métrica permite analizar la eficiencia del sistema durante la interacción con los usuarios.

El tiempo de respuesta se define como el intervalo que transcurre entre el momento en que el estudiante formula una consulta y el momento en que el sistema genera la respuesta correspondiente. Esta medición permite evaluar el desempeño del sistema en aplicaciones interactivas donde la rapidez de respuesta resulta importante para mantener una conversación fluida.

4.6.3 EVALUACIÓN DE SATISFACCIÓN DEL USUARIO

Además de las métricas técnicas del sistema, se evaluó la percepción de los usuarios respecto a la utilidad del robot como herramienta de apoyo académico.

Para ello se aplicaron encuestas de satisfacción a los estudiantes que participaron en las pruebas del sistema. Estas encuestas permitieron recopilar información sobre distintos aspectos de la interacción, tales como:

- claridad de las respuestas proporcionadas
- facilidad de interacción con el robot
- utilidad percibida del sistema para resolver consultas académicas

La información obtenida mediante estas encuestas permitió complementar el análisis técnico del sistema con la experiencia de los usuarios durante la interacción.

4.6.4 ANÁLISIS DE RESULTADOS

Los datos obtenidos durante las pruebas y encuestas fueron analizados con el objetivo de evaluar el desempeño del sistema desarrollado. Este análisis permitió identificar fortalezas, limitaciones y posibles mejoras para futuras versiones del sistema.

La combinación de métricas técnicas y evaluación de percepción del usuario permitió obtener una visión integral del funcionamiento del sistema conversacional implementado en el robot humanoide ADAI.

4.7 CRONOGRAMA DE ACTIVIDADES

Tabla 2-Cronograma de actividades a realizar durante el proyecto

ACTIVIDADES	SEMANA									
	1	2	3	4	5	6	7	8	9	10
ETAPA DE PLANEACIÓN										
Definición del alcance del proyecto										
Definición de objetivos de investigación										
Identificación del problema y antecedentes										
DISEÑO										
Diseño de la arquitectura del sistema RAG										
COMIENZO DEL DESARROLLO										
Procesamiento de documentos y generación de embeddings										
Implementación del sistema conversacional										
Integración con el robot ADAI										
EVALUACIÓN										
Pruebas del sistema con estudiantes										
Análisis de resultados										
DOCUMENTACIÓN										
Redacción del informe final										
Redacción del artículo científico										
SEGUIMIENTO										
Reuniones con asesor										

Fuente: (Propia del autor)

BIBLIOGRAFÍA

- Breazeal, C. (2003). Toward sociable robots. *Robotics and Autonomous Systems*, 42(3–4), 167–175.
- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., . . . Ra. (2020). Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems*.
- Dautenhahn, K. (2007). Socially intelligent robots: Dimensions of human–robot interaction. *Philosophical Transactions of the Royal Society B*, 362(1480), 679–704.
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *NAACL-HLT*.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. Cambridge, Massachusetts: MIT Press.
- Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., . . . Fung, P. (2023). Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*.
- Johnson, J., Douze, M., & Jégou, H. (2019). Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*.
- Jurafsky, D., & Martin, J. H. (2021). *Speech and Language Processing (3rd ed., draft version)*. Pearson (draft académico en línea).
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., . . . Kiela, D. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems*.
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge, Reino Unido: Cambridge University Press.
- Mikolov, T., Sutskever, I., Chen, K., Corrado, G. S., & Dean, J. (2013). Efficient Estimation of Word Representations in Vector Space. *arXiv preprint*.
- Mubin, O., Stevens, C., Shahid, S., Al Mahmud, A., & Dong, J.-J. (2013). A review of the applicability of robots in education. *Technology for Education and Learning*, 1(1), 1–7.
- Nielsen, J. (1993). *Usability Engineering*. San Francisco, Estados Unidos: Morgan Kaufmann.

- Pressman, R. S., & Maxim, B. R. (2020). *Software Engineering: A Practitioner's Approach*. Nueva York, Estados Unidos: McGraw-Hill Education.
- Radford, A., Narasimhan, K., Salimans, T., & Sutskever, I. (2018). Improving Language Understanding by Generative Pre-Training. *OpenAI*.
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *arXiv*.
- Russell, S., & Norvig, P. (2021 (4th edition)). *Artificial Intelligence: A Modern Approach*. Nueva York, Estados Unidos: Pearson.
- Sommerville, I. (2016). *Software Engineering*. Boston, Estados Unidos: Pearson.
- Van Rossum, G., & Drake, F. (2009). *The Python Language Reference Manual*. Python Software Foundation.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., N. Gomez, A., . . . Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems (NeurIPS)*.